


**MINISTÉRIO DA DEFESA
DEPARTAMENTO DE CIÊNCIA E TECNOLOGIA
INSTITUTO MILITAR DE ENGENHARIA
Seção de Engenharia de Defesa (SE/10)**



EE 600200: Álgebra Linear Computacional

Lista de Exercícios #3

Cap Suzane GAERTNER Martins

Rio de Janeiro, RJ
JUNHO de 2025

1ª Questão

[FORD] Exercício 9.2: forneça a contagem de flops para cada operação de matriz.

a. Multiplicação de uma Matriz A $m \times n$ por um vetor x $n \times 1$

Cada elemento do resultado é um produto interno de uma linha de A pelo vetor x :

- Cada linha: n multiplicações + $n - 1$ somas, resultando em $2n - 1$ flops;
- Total para m linhas: $m(2n - 1)$ flops.

b. O produto xy^T , onde x é $m \times 1$ e y é $p \times 1$

xy^T resulta em uma matriz $m \times p$, onde cada elemento é $x_i \cdot y_j$

- Cada elemento: 1 multiplicação;
- Total: $m \times p$ multiplicações (sem somas).

c. Se u e v são vetores $n \times 1$, calcule $\left(\frac{\langle v, u \rangle}{\|u\|^2}\right) u$

Passos:

1. $\langle v, u \rangle$: n multiplicações + $n - 1$ somas resultando em $2n - 1$ flops;
2. $\|u\|^2$: n multiplicações + $n - 1$ somas resultando em $2n - 1$ flops;
3. Divisão de escalares: 1 flop;
4. Multiplicação escalar por vetor: n multiplicações

Total:

$$(2n - 1) + (2n - 1) + 1 + n = 5n - 1$$

d. $\|A\|_\infty$ para matriz A $m \times n$

($\|A\|_\infty$ é o maior valor absoluto da soma dos elementos por linha)

Para cada linha:

- $n - 1$ somas para cada linha, m linhas $\rightarrow m(n - 1)$ flops;
- Encontrar máximo entre m somas: $m - 1$ comparações/flops.

Total:

$$m(n - 1) + (m - 1)$$

e. $\|A\|_1$ para matriz A $m \times n$

($\|A\|_1$ é o maior valor absoluto da soma dos elementos por coluna)

Para cada coluna:

- $m - 1$ somas por coluna, n colunas $\rightarrow n(m - 1) \text{ flops}$;
- Encontrar máximo entre n somas: $n - 1$ comparações/flops.

Total:

$$n(m - 1) + (n - 1)$$

f. $\text{traço}(A)$, onde A é uma matriz $n \times n$

O traço de A é a soma dos elementos da diagonal:

- $n - 1$ somas (nenhuma multiplicação é necessária).

Total: $n - 1$ flops

2ª Questão

[FORD] Exercício 9.18: Implemente o problema que calcula o produto vetorial de vetores u e v , em uma função Python chamada `crossprod`. Após a implementação, crie vetores u e v e calcule:

- $u \times v$
- $v \times u$
- $\langle u \times v, u \rangle$
- $\langle v \times u, v \rangle$

Solução

Arquivo “`crossprod.py`”

```
1 import numpy as np
2
3 def crossprod(u, v):
4     """
5     Calcula o produto vetorial entre dois vetores 3D u e v.
6     """
7     x = u[1]*v[2] - u[2]*v[1]
8     y = u[2]*v[0] - u[0]*v[2]
9     z = u[0]*v[1] - u[1]*v[0]
10    return np.array([x, y, z])
11
12 # Exemplos de vetores
13 u = np.array([1, 2, 3])
14 v = np.array([4, 5, 6])
15
16 # Produto vetorial
17 uv = crossprod(u, v)
18 vu = crossprod(v, u)
19
20 print('u x v =', uv)
21 print('v x u =', vu)
22
23 # Produto escalar entre (u x v) e u
24 dot1 = np.dot(uv, u)
25 # Produto escalar entre (v x u) e v
26 dot2 = np.dot(vu, v)
```

```
27
28 print('(u x v) · u =', dot1)
29 print('(v x u) · v =', dot2)
```

Para os vetores $u = [1, 2, 3]$ e $v = [4, 5, 6]$, a saída é:

$$u \times v = [-3, 6, -3]$$

$$v \times u = [3, -6, 3]$$

$$(u \times v) \cdot u = 0$$

$$(v \times u) \cdot v = 0$$

3ª Questão

[FORD] Exercício 10.6: Seja $f(x) = \ln x$

a. Mostre que o número de condicionamento de f em x é $c(x) = \frac{1}{|\ln x|}$

O número de condicionamento relativo de uma função $f(x)$ no ponto x é dado por:

$$c(x) = \left| \frac{x f'(x)}{f(x)} \right|$$

Para $f(x) = \ln x$:

$$f'(x) = \frac{1}{x}$$

Substituindo:

$$c(x) = \left| \frac{x \cdot \frac{1}{x}}{\ln x} \right| = \left| \frac{1}{\ln x} \right|$$

Portanto,

$$\boxed{c(x) = \frac{1}{|\ln x|}}$$

b. Usando o resultado acima, mostre que $\ln x$ é mal-condicionada perto de $x = 1$

Quando x se aproxima de 1, temos que $\ln x \rightarrow 0$.

Pela fórmula do número de condicionamento:

$$c(x) = \frac{1}{|\ln x|}$$

Logo, quando $x \rightarrow 1$, $|\ln x| \rightarrow 0$ e, portanto, $c(x) \rightarrow \infty$.

Assim, o número de condicionamento torna-se muito grande quando x está próximo de 1, indicando que pequenas variações em x podem causar grandes variações em $\ln x$.

Conclusão: $\ln x$ é **mal-condicionada** (*ill-conditioned*) perto de $x = 1$, pois o número de condicionamento tende ao infinito nessa região.

4ª Questão

[FORD] Exercício 10.12: Seja $A = \begin{bmatrix} 1 & a \\ a & 1 \end{bmatrix}$. Para quais valores de a a matriz A é mal-condicionada?

O número de condicionamento na norma 2 de uma matriz simétrica é dado por:

$$\kappa_2(A) = \frac{\max(|\lambda_1|, |\lambda_2|)}{\min(|\lambda_1|, |\lambda_2|)}$$

onde λ_1 e λ_2 são os autovalores de A .

Os autovalores de A são obtidos resolvendo:

$$\det(A - \lambda I) = 0$$

$$\begin{vmatrix} 1 - \lambda & a \\ a & 1 - \lambda \end{vmatrix} = (1 - \lambda)^2 - a^2 = 0$$

$$(1 - \lambda)^2 = a^2$$

$$1 - \lambda = \pm a$$

$$\lambda = 1 \mp a$$

Logo, os autovalores são:

$$\lambda_1 = 1 + a, \quad \lambda_2 = 1 - a$$

Assim,

$$\kappa_2(A) = \frac{\max(|1 + a|, |1 - a|)}{\min(|1 + a|, |1 - a|)}$$

A matriz é mal-condicionada quando o denominador se aproxima de zero, ou seja, quando $|1 + a|$ ou $|1 - a|$ é próximo de zero. Portanto,

A é mal-condicionada para $a \approx 1$ ou $a \approx -1$.

O que acontece quando $a \rightarrow \infty$?

Quando a tende ao infinito,

$$\lambda_1 \approx a, \quad \lambda_2 \approx -a$$

Os módulos dos autovalores são iguais: $|\lambda_1| \approx |\lambda_2| \approx |a|$.

Assim,

$$\kappa_2(A) = \frac{|a|}{|a|} = 1$$

Portanto, à medida que $a \rightarrow \infty$, a matriz A se torna bem-condicionada, pois o número de condicionamento tende a 1.

Resumo:

- A é mal-condicionada para valores de a próximos de 1 ou -1 , pois um dos autovalores se aproxima de zero, tornando a matriz quase singular.
- Quando $a \rightarrow \infty$ (ou $a \rightarrow -\infty$), A se torna bem-condicionada, pois os autovalores têm grandes módulos e o número de condicionamento tende a 1.

5ª Questão

[FORD] Exercício 10.21:

A matriz bidiagonal de Wilkinson tem a forma geral

$$A = \begin{bmatrix} n & n & & & \\ & n-1 & n & & \\ & & \ddots & \ddots & \\ & & & 2 & n \\ & & & & 1 \end{bmatrix}$$

e é frequentemente utilizada para fins de teste.

- (a) Crie uma função anônima utilizando `diag` que construa uma matriz bidiagonal de Wilkinson de ordem $n \times n$.
- (b) Faça o gráfico do número de condição das matrizes bidiagonais de Wilkinson de ordem 1 até 15. Quais são suas conclusões?
- (c) Autovalores são difíceis de calcular com precisão. A matriz bidiagonal de Wilkinson 20×20 , A , possui autovalores $\lambda = 20, 19, \dots, 1$. Esta matriz ilustra que, mesmo quando os autovalores de uma matriz não são iguais ou nem mesmo próximos, um problema de autovalores pode ser mal condicionado. Calcule os autovalores de A , perturbe $A(20, 1)$ por 10^{-10} e calcule novamente os autovalores. Comente os resultados.

(OBS.: ignorar a parte de a função pedida na letra (a) ser uma "anonymous function". Basta criar uma função no padrão do Python.)

Solução

Arquivo "wilkinson_bidiagonal.py"

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 def wilkinson_bidiagonal(n):
5     A = np.zeros((n, n))
6     for i in range(n):
7         A[i, i] = n - i      # Diagonal principal
8     for i in range(n-1):
9         A[i, i+1] = n       # Diagonal superior
10    return A
```

```

11
12 # Exemplo
13 print(wilkinson_bidiagonal(5))
14
15 cond_numbers = []
16 orders = range(1, 16)
17
18 for n in orders:
19     A = wilkinson_bidiagonal(n)
20     cond = np.linalg.cond(A)
21     cond_numbers.append(cond)
22
23 # Gráfico do número de condicionamento
24 plt.figure(figsize=(8,5))
25 plt.plot(orders, cond_numbers, marker='o')
26 plt.xlabel('Ordem da matriz (n)')
27 plt.ylabel('Número de condicionamento (cond)')
28 plt.title('Número de condicionamento da matriz bidiagonal de
    ↳ Wilkinson')
29 plt.grid(True)
30 plt.show()
31
32 # Matriz original
33 n = 20
34 A = wilkinson_bidiagonal(n)
35 eigvals_original = np.linalg.eigvals(A)
36
37 # Perturbação: soma 1e-10 ao elemento (20,1)
38 A_perturbed = A.copy()
39 A_perturbed[-1, 0] += 1e-10
40 eigvals_perturbed = np.linalg.eigvals(A_perturbed)
41
42 # Comparação dos autovalores
43 print("Autovalores originais:\n",
    ↳ np.sort(np.real(eigvals_original)))
44 print("\nAutovalores após perturbação:\n",
    ↳ np.sort(np.real(eigvals_perturbed)))
45 print("\nDiferença máxima:",
    ↳ np.max(np.abs(np.sort(np.real(eigvals_original)) -
    ↳ np.sort(np.real(eigvals_perturbed)))))
46

```

b) Gráfico do número de condicionamento das matrizes Wilkinson de ordem 1 a 15:




Figura 1: Número de condicionamento da matriz bidiagonal de Wilkinson para ordens de 1 a 15.

Conclusão: O gráfico mostra que o número de condicionamento cresce rapidamente com o aumento de n , tornando a matriz cada vez mais mal-condicionada para valores altos de n . Ou seja, pequenas perturbações nos elementos podem causar grandes variações nos resultados de operações com essas matrizes.

c) Autovalores e instabilidade:

```
Autovalores originais:
[ 1.  2.  3.  4.  5.  6.  7.  8.  9. 10. 11. 12. 13. 14. 15. 16. 17. 18.
 19. 20.]

Autovalores após perturbação:
[ 0.99575439  2.10924185  2.57488136  3.96533065  3.96533065  5.89397763
 5.89397763  8.11807374  8.11807374 10.50000052 10.50000052 12.88192687
12.88192687 15.10602214 15.10602214 17.03466871 17.03466871 18.42511789
18.89075841 20.00424561]

Diferença máxima: 1.1060223749669227
PS C:\Users\suzi_\OneDrive\Área de Trabalho\Mestrado\Alg Lin Comp>
```

Figura 2: Autovalores após perturbações.

Comentário: Mesmo uma perturbação minúscula (10^{-10}) pode causar variações relevantes nos autovalores dessa matriz. Isso ilustra a instabilidade numérica: ainda que os autovalores sejam bem separados, o problema de autovalores pode ser mal-condicionado, e pequenos erros nos dados de entrada podem ser amplificados no resultado.

Resumo:

- A matriz Wilkinson bidiagonal é útil para testar algoritmos porque se torna rapidamente mal-condicionada com o aumento da ordem.
- O número de condicionamento cresce muito rápido com n , tornando operações numéricas instáveis para matrizes grandes.
- Uma perturbação muito pequena pode alterar significativamente os autovalores, mostrando que nem sempre autovalores bem separados garantem estabilidade numérica.